

**UNIVERSIDAD TÉCNICA FEDERICO SANTA MARÍA**

**DEPARTAMENTO DE MATEMÁTICA**

**Análisis de Imágenes transformadas con Box  
Cox**

Memoria de Título presentada por

**Fabián Castellano Núñez**

como requisito parcial para optar al título de

**Ingeniero Civil Matemático**

Profesor Guía

Dr. Ronny Vallejos S.

Martes XX de Diciembre, 2023.



# Capítulo 1

## Introducción

A lo largo de la literatura se suele aplicar la transformación a vectores unidimensionales, y no ha sido extendida a matrices  $d$ -dimensionales en las que existe correlaciones de adyacencia, excepto en el trabajo de Bicego y Baldo (*Properties of the Box-Cox Transformation for Pattern Classification*), y en (*MR Image Segmentation Using a Power Transformation Approach*), en ambos solo se propone una transformación que lleve las  $d$  dimensiones a 1.

## Capítulo 2

# Análisis Estadístico y Procesamiento de Imágenes

### 2.1. Definiciones previas

asdf



## Capítulo 3

# Coeficientes para la comparación entre dos imagenes

La creciente dimensionalidad de los conjuntos de datos utilizados comunmente ha llevado a la popularidad concepto de la ciencia generadora de hipótesis, en la cual los conjuntos de datos se utilizan para ayudar a los investigadores a formular nuevas hipótesis en lugar de probar las existentes. En este enfoque, se utilizan medidas de dependencia, que son estadísticas empleadas para evaluar pares de variables candidatas. Estos avances en el campo nos han entregado muchas herramientas, tanto para la comparación de datos en si mismos, junto con formas de avaluar estas medidas en si mismas.

Una forma de evaluar la utilidad de una medida de dependencia es examinar su potencia contra la independencia, lo que implica detectar varios tipos de relaciones no triviales. Este enfoque es especialmente importante cuando los conjuntos de datos tienen pocas o débiles relaciones que son difíciles de detectar. Sin embargo, a menudo el número de relaciones estadísticamente significativas supera lo que se puede explorar más a fondo, como se observa en los conjuntos de datos biológicos. Restringir el seguimiento a las relaciones con los valores de más altos puede sesgar la dirección del trabajo de seguimiento, ya que puede asignar puntuaciones más altas a tipos de relación específicos, como las relaciones lineales, sobre las no lineales.

Para abordar este problema, se introdujo un segundo método de evaluación de una medida de dependencia llamado equitabilidad (Reshef et al., 2011). Las estadísticas equitativas asignan puntuaciones similares a relaciones igualmente fuertes, independientemente de su tipo. El objetivo es definir medidas de dependencia que logren una buena equitabilidad con respecto a medidas relevantes de la fuerza de la relación.

La idea de equitabilidad ha motivado el desarrollo de varias medidas de dependencia, con diferentes formalizaciones y enfoques en aspectos específicos de la fuerza de la relación. El desafío radica en definir medidas de dependencia que logren una buena equitabilidad con respecto a medidas importantes de la fuerza de la relación, como se ve en el artículo complementario de Reshef et al. Esta línea de investigación tiene como objetivo proporcionar un enfoque más poderoso y equitativo para medir la dependencia, lo que permite una identificación y priorización más precisas de las relaciones en conjuntos de datos complejos.

Con esto en mente, en esta sección estudiaremos el coeficiente de información máxima (MIC), Correlación local, y la correlación de Pearson; los cuales son los coeficientes más utilizados para la comparación entre dos imágenes. Notemos que que ya fue mostrado por Reshef et al (2011) que el coeficiente de información máxima (MIC) es equitativo, estudiaremos la equitatividad de los otros dos coeficientes más adelante.

### 3.1. *Maximal Information Coefficient*

#### 3.1.1. Sobre el coeficiente

El coeficiente de información máxima (Maximal Information Coefficient o MIC) es una medida estadística propuesta por Reshef et al. en su paper "Detecting Novel Associations in Large Data Sets" [citar]. Este coeficiente mide la correlación entre dos variables en un conjunto de datos y se basa en la idea de que una relación fuerte entre dos variables debería ser capaz de predecir una variable a partir de la otra de manera precisa.

En su paper, Reshef et al. presentan un enfoque innovador para detectar asociaciones nobles en grandes conjuntos de datos, en lugar de buscar correlaciones fuertes entre dos variables, el coeficiente MIC permite detectar relaciones débiles pero aún importantes que pueden no ser evidentes al simplemente mirar los datos. Esto es posible gracias a que el coeficiente MIC es capaz de capturar no solo la fuerza de la correlación entre dos variables, sino también su precisión.

Para calcular el coeficiente, se parte de la idea de que la información mutua entre dos variables es una medida de la precisión con la que se puede predecir una variable a partir de la otra. Por lo tanto, el coeficiente se calcula como la información mutua máxima posible entre dos variables, dado un conjunto de datos. Esto se hace a través de un procedimiento iterativo en el que se prueban diferentes particiones de los datos en conjuntos de entrenamiento y prueba, y se selecciona aquella que maximiza la información mutua.

En la siguiente sección estudiaremos las definiciones que nos entrega cada coeficiente.

### 3.1.2. Definiciones

Como mencionamos en la parte anterior, debemos primero encontrar la información mutua entre las variables, para esto definamos:

**Definición 3.1** (Información mutua). Para dos variables aleatorias conjuntas  $X$  e  $Y$ , se define la información mutua como:

$$I(X; Y) = \int_Y \int_X P_{(X,Y)}(x, y) \log \left( \frac{P_{(X,Y)}(x, y)}{P_X(x)P_Y(y)} \right) dx dy$$

Donde  $P_{(X,Y)}$  es la función de densidad de probabilidad conjunta y  $P_X$ ,  $P_Y$ , las distribuciones marginales de  $X$  e  $Y$  respectivamente.

Luego, sea  $D$  un conjunto finito de pares ordenados, podemos particionar los valores de la primera coordenada en  $x$  contenedores, y los valores de la segunda en  $y$  de estos. Dado una malla  $G$ , sea  $D|_G$  la distribución inducida por los puntos de  $D$  en las celdas de  $G$ , i.e., la distribución en las celdas de  $G$  obtenida al dejar que la función de densidad de probabilidad en cada celda sea la fracción de puntos de  $D$  que caen en esa celda. Veamos un ejemplo




Figura 3.1: Malla  $G$  de  $4 \times 3$  sobre el conjunto de pares ordenados  $D$ , figura no final

Para la figura 3.1, la función de densidad quedaría de la forma:

$$f_{D|G}(i, j) = \begin{cases} \frac{2}{10} & \text{si } (i, j) \in \{(1, 1), (2, 2), (4, 2)\} \\ \frac{1}{10}, & \text{si } (i, j) \in \{(3, 2)\} \\ \frac{3}{10}, & \text{si } (i, j) \in \{(4, 1)\} \\ 0, & \text{Otro caso.} \end{cases}$$

Notemos que para un  $D$  fijo, aunque fijemos el grosor de la malla, la distribución de esta puede variar dependiendo de donde hagamos los cortes, por ejemplo:






Figura 3.2: Otra malla  $G$  de  $4 \times 3$  sobre el conjunto de pares ordenados  $D$ , figura no final

Aquí podemos ver que la función de densidad que nos entrega esta malla es distinta a la definida para la figura 3.2. Este es un hecho que explotamos en la siguiente definición:

**Definición 3.2.** Para un conjunto finito  $D \in \mathbb{R}^2$  y enteros positivos  $i, j$ , definimos:

$$I^*(D, i, j) = \max I(D|_G)$$

donde el máximo es sobre todas las mallas  $G$  con  $i$  columnas y  $j$  filas, con  $I(D|_G)$  denot la información mutua de  $D|_G$ .

Ya teniendo este valor procedemos a definir la matriz característica del conjunto  $D$ .

**Definición 3.3.** La matriz característica  $M(D)$  de un conjunto bivariado  $D$  es una matriz infinita con entradas:

$$M(D)_{x,y} = \frac{I^*(D, x, y)}{\log \min\{x, y\}}$$

**Definición 3.4.** El coeficiente de información máxima o *MIC* de un conjunto bivariado  $D$  de tamaño  $n$  y una malla de tamaño menos a  $B(n)$  está dado por:

$$\text{MIC}(D) = \max_{xy < B(n)} \{M(D)_{x,y}\}$$

donde  $\omega(1) < B(n) \leq O(n^{1-\varepsilon})$  para algún  $0 < \varepsilon < 1$

*Observación 3.1.* A menos que se especifique de otra forma, al momento de trabajar con esta medida usaremos  $B(n) = n^{0.6}$ , que es la función que ocupan en el paper citado al principio de la sección

### 3.1.3. Formas prácticas de calcular el MIC, el $MIC_*$ , $TIC_e$ y $MIC_e$

En el artículo "Measuring Dependence Powerfully and Equitably" de Reshef et al., los autores presentan y caracterizan teóricamente dos nuevas medidas de dependencia:  $MIC_*$  y  $MIC_e$ .  $MIC_*$  es una medida de dependencia poblacional, y el artículo presenta tres formas de ver esta cantidad. Los autores demuestran que  $MIC_*$  es el valor poblacional del coeficiente de información máxima (MIC), una suavización mínima de la información mutua y el supremo de una secuencia infinita. Estas caracterizaciones simplifican el cálculo y fortalecen los resultados teóricos.

Además, los autores desarrollan algoritmos eficientes para aproximar  $MIC_*$  en la práctica y estimarlo de manera consistente a partir de una muestra finita. Introducen  $MIC_e$ , un estimador consistente de  $MIC_*$ , que es computable de manera eficiente y más rápido en la práctica que el algoritmo heurístico para calcular MIC. A través de simulaciones, demuestran que  $MIC_e$  tiene mejores propiedades de sesgo/varianza y supera a los métodos existentes en términos de equitabilidad con respecto a R2 en un amplio conjunto de relaciones funcionales ruidosas.

### 3.1.4. Definiciones y propiedades de $MIC_*$

En esta sección, abordaremos las definiciones esenciales para el cálculo del  $MIC_e$ . El coeficiente máximo de información poblacional puede expresarse de diversas maneras equivalentes, como veremos más adelante. Sin embargo, comenzaremos con la definición más sencilla.

**Definición 3.5.** Sea  $(X, Y)$  una pareja de variables aleatorias conjuntamente distribuidas. El coeficiente de información máxima poblacional ( $MIC_*$ ) de  $(X, Y)$  se define como:

$$MIC_*(X, Y) = \sup_G \frac{I((X, Y)|_G)}{\log \|G\|}$$

donde  $\|G\|$  denota el mínimo entre el número de filas y el número de columnas de  $G$ .

Ya que  $I(X, Y) = \sup_G I((X, Y)|_G)$  (consultar, por ejemplo, el Capítulo 8 de Cover y Thomas, 2006), esto puede interpretarse como una versión regularizada de la información mutua que sanciona las rejillas complejas y garantiza que el resultado esté dentro del rango entre cero y uno.

Previo a continuar, introducimos una definición equivalente y sencilla de  $MIC_*$  que resulta útil para los resultados en esta sección. Esta definición considera a  $MIC_*$  como el supremo de una matriz denominada matriz característica poblacional, que se define a continuación.

**Definición 3.6.** Sea  $(X, Y)$  una pareja de variables aleatorias conjuntamente distribuidas. Sea

$$I^*((X, Y), k, \ell) = \max_{G \in G(k, \ell)} I((X, Y)|_G)$$

La matriz característica poblacional de  $(X, Y)$ , denotada por  $M(X, Y)$ , se define como

$$M(X, Y)_{k, \ell} = \frac{I^*((X, Y), k, \ell)}{\log \min\{k, \ell\}}$$

para  $k, \ell > 1$ .

Es fácil ver lo siguiente:

Proposición 3: Sea  $(X, Y)$  una pareja de variables aleatorias conjuntamente distribuidas. Tenemos

$$MIC * (X, Y) = \sup M(X, Y)$$

donde  $M(X, Y)$  es la matriz característica poblacional de  $(X, Y)$ .

La matriz característica poblacional recibe este nombre porque, al igual que el  $MIC^*$ , el supremo de esta matriz, captura una noción de la intensidad de la relación, y otras propiedades de esta matriz se relacionan con diferentes características de las relaciones. Por ejemplo, más adelante en este documento presentamos una propiedad adicional de la matriz característica, el coeficiente de información total, que es útil para comprobar la presencia o ausencia de una relación en lugar de cuantificar la intensidad de la relación.

### 3.2. El $MIC_*$ es el valor poblacional del $MIC$

Con el  $MIC_*$  definido, presentamos nuestra primera caracterización alternativa de este, como el límite de muestra grande del estadístico  $MIC$  introducido en Reshef et al. (2011). Recordemos la Definiciones del  $MIC$  y la matriz característica de muestra. Notemos que para evitar confusión denotaremos como  $MIC$  al estadístico  $MIC$  y como  $MIC_*$  al coeficiente de información máxima poblacional.

**Definición 3.7.** (Reshef et al., 2011) Sea  $D \subset \mathbb{R}^2$  un conjunto de pares ordenados. La matriz característica de muestra  $\widehat{M}(D)$  de  $D$  se define por

$$\widehat{M}(D)_{k, \ell} = \frac{I^*(D, k, \ell)}{\log \min\{k, \ell\}}.$$

**Definición 3.8.** (Reshef et al., 2011) Sea  $D \subset \mathbb{R}^2$  un conjunto de  $n$  pares ordenados, y sea  $B : \mathbb{Z}^+ \rightarrow \mathbb{Z}^+$ . Definimos

$$MIC(D) = \max_{k, \ell \leq B(n)} \widehat{M}(D)_{k, \ell}$$

Donde la función  $B(n)$  es especificada por el usuario. En Reshef et al. (2011), se sugirió que  $B(n)$  se elija como  $n^\alpha$  para alguna constante  $\alpha$  en el rango de 0.5 a 0.8. (Los estadísticos que presentaremos más adelante tendrán un parámetro análogo; véase la Sección 4.4.1.)

El siguiente resultado, demostrado en el paper de Reshef 2016, sobre la convergencia de funciones de la matriz característica de muestra a sus contrapartes poblacionales, una consecuencia de lo cual es la convergencia de  $MIC$  a  $MIC_*$ . (En la declaración del teorema a continuación, recordemos que  $m_\infty$  es el espacio de matrices infinitas equipadas con la norma supremo, y dada una matriz  $A$ , la proyección  $r_i$  anula todas las entradas  $A_{k,\ell}$  para las cuales  $k\ell > i$ .)

**Teorema 3.1.** *Sea  $f : m_\infty \rightarrow \mathbb{R}$  uniformemente continua, y suponga que  $f \circ r_i \rightarrow f$  puntualmente. Entonces, para cada variable aleatoria  $(X, Y)$ , tenemos*

$$(f \circ r_{B(n)}) \left( \widehat{M}(D_n) \right) \rightarrow f(M(X, Y))$$

en probabilidad donde  $D_n$  es una muestra de tamaño  $n$  de la distribución de  $(X, Y)$ , siempre que  $\omega(1) < B(n) \leq O(n^{1-\varepsilon})$  para algún  $\varepsilon > 0$ .

Dado que el supremo de una matriz es una función uniformemente continua en  $m_\infty$  y se puede realizar como el límite de máximos de segmentos cada vez más grandes de la matriz, este teorema genera nuestra afirmación sobre  $MIC_*$  como corolario.

Corolario 7:  $MIC$  es un estimador consistente de  $MIC_*$  siempre que  $\omega(1) < B(n) \leq O(n^{1-\epsilon})$  para algún  $\epsilon > 0$ .

Ya con esto podemos trabajar, bajo ciertas condiciones, con el  $MIC_*$  como reemplazo del  $MIC$ . Pero, ¿Cuál es la ventaja de trabajar con este nuevo estimador? En pocas palabras, es más fácil de estimar, y esto lo veremos en la en una sección más adelante. Antes de esto debemos revisar una caracterización del  $MIC_*$  que nos permitirá contruir un estimador de este.

### 3.2.1. El $MIC_*$ es el supremo de la matriz característica de muestra

Ahora mostramos la una vista alternativa de  $MIC_*$ : que puede definirse de manera equivalente como el supremo sobre un límite de la matriz característica en lugar de como un supremo sobre todas las entradas de la matriz. Esta caracterización de  $MIC_*$  servirá como base tanto para nuestro enfoque de aproximación de  $MIC_*(X, Y)$  como para el nuevo estimador de  $MIC_*$  que presentamos más adelante en este artículo.

Comenzamos definiendo lo que entendemos por límite de la matriz característica. Nuestra definición se basa en la siguiente observación.

**Proposición 3.1.** Sea  $M$  una matriz característica poblacional. Entonces, para  $\ell \geq k$ ,  $M_{k,\ell} \leq M_{k,\ell+1}$

*Demostración.* Sea  $(X, Y)$  la variable aleatoria en cuestión. Dado que siempre podemos dejar una fila/columna vacía, sabemos que  $I^*((X, Y), k, \ell) \leq I^*((X, Y), k, \ell + 1)$ . Y dado que  $\ell, \ell + 1 \geq k$ , sabemos que  $M_{k, \ell} = I^*((X, Y), k, \ell) / \log k \leq I^*((X, Y), k, \ell + 1) / \log k = M_{k, \ell + 1}$ .  $\square$

Dado que las entradas de la matriz característica están acotadas, el teorema de convergencia monótona nos da el siguiente corolario. En el corolario y en adelante, dejamos  $M_{k, \uparrow} = \lim_{\ell \rightarrow \infty} M_{k, \ell}$  y definimos  $M_{\uparrow, \ell}$  de manera similar.

**Corolario 3.2.** *Sea  $M$  una matriz característica poblacional. Entonces,  $M_{k, \uparrow}$  existe, es finito e igual a  $\sup_{\ell \geq k} M_{k, \ell}$ . Lo mismo es válido para  $M_{\uparrow, \ell}$ .*

El corolario anterior nos permite definir el límite de la matriz característica.

**Definición 3.9.** Sea  $M$  una matriz característica poblacional. El límite de  $M$  es el conjunto

$$\partial M = \{M_{k, \uparrow} : 1 < k < \infty\} \cup \{M_{\uparrow, \ell} : 1 < \ell < \infty\}$$

El teorema siguiente da una relación entre el límite de la matriz característica y  $MIC_*$ .

**Teorema 3.3.** *Sea  $(X, Y)$  una variable aleatoria. Tenemos*

$$MIC_*(X, Y) = \sup \partial M(X, Y)$$

donde  $M(X, Y)$  es la matriz característica poblacional de  $(X, Y)$ .

*Demostración.* El siguiente argumento muestra que cada entrada de  $M$  es, como máximo,  $\sup \partial M$ : fije un par  $(k, \ell)$  y observe que, o bien  $k \leq \ell$ , en cuyo caso  $M_{k, \ell} \leq M_{k, \uparrow}$ , o bien  $\ell \leq k$ , en cuyo caso  $M_{k, \ell} \leq M_{\uparrow, \ell}$ .

Por lo tanto,

$$MIC_* \leq \sup \{M_{\uparrow, \ell}\} \cup \{M_{k, \uparrow}\} = \sup \partial M \quad \square$$

Por otro lado, el Corolario muestra que cada elemento de  $\partial M$  es un supremo sobre algunos elementos de  $M$ . Por lo tanto,  $\sup \partial M$ , al ser un supremo sobre supremos de elementos de  $M$ , no puede exceder  $\sup M = MIC_*$ .

### 3.3. Estimando el $MIC_*$ con $MIC_e$

Como hemos revisado,  $MIC_*$  es el valor poblacional del estadístico MIC introducido en Reshef et al. (2011). Sin embargo, aunque es consistente, el estadístico MIC no se conoce por ser eficientemente computable y en Reshef et al. (2011) se calculó en su lugar un algoritmo heurístico de aproximación llamado Approx-MIC. En esta sección, revisaremos un estimador de  $MIC_*$  que es tanto consistente como eficientemente computable. El nuevo estimador, llamado  $MIC_e$ ,

tiene una mejor complejidad de tiempo de ejecución incluso que el algoritmo heurístico Approx-MIC y es órdenes de magnitud más rápido en la práctica.

El estimador  $MIC_e$  se basa en una de las caracterizaciones alternativas de  $MIC_*$  probadas en la sección anterior. Específicamente, si  $MIC_*$  puede considerarse como el supremo del límite de la matriz característica en lugar de la matriz completa, entonces solo el límite de la matriz debe estimarse con precisión para estimar  $MIC_*$ . Esto tiene la ventaja de que, mientras que calcular entradas individuales de la matriz característica de muestra implica encontrar rejillas óptimas (bidimensionales), estimar las entradas del límite nos requiere solo encontrar particiones óptimas (unidimensionales). Si bien el primer problema es computacionalmente difícil, el segundo puede resolverse utilizando el algoritmo de programación dinámica de Reshef et al. (2011).

*resumir la sección 4 de Reshef 2016*

### 3.3.1. Ejemplos

Ya con la función bien definida, veamos unos ejemplos del coeficiente, primero para algunos datos, y luego entre imágenes. Comencemos por algunos ejemplos usando

el formato de esta sección es temporal




Figura 3.3:  $MIC = 0.187$




Figura 3.4: MIC = 0.227




Figura 3.5: MIC = 0.176




Figura 3.6: MIC = 0.425




Figura 3.7: MIC = 0.631






Figura 3.8:  $\text{MIC} = 0.228$




Figura 3.9:  $\text{MIC} = 0.257$




Figura 3.10: MIC = 0.500




Figura 3.11: MIC = 0.157




Figura 3.12: MIC = 0.212

### 3.4. Correlación local

#### 3.4.1. Discucion sobre el coef.

donde se publico, como su ocupa, despicion en palabras

La correlación local, también conodica como coeficiente no paramétrico de Chen, o coeficiente de Chen. Este, sin realizar supuestos sobre distribuciones, detecta relaciones no lineales al invenstigar un montón de correalciones locales.

#### 3.4.2. Definiciones

La definición del método está basada en en el concepto de integrales de correlación, las cuales se definen de la siguiente forma:

**Definición 3.10.**

$$I(r) = \lim_{N \rightarrow \infty} \left\{ \frac{1}{N^2} \sum_{i,j=1}^N I(|z_i - z_j| < r) \right\}$$

La integral de correlación cuantifica el el número promedio de vecinos dentro de un radio  $r$ . Notemos que esta definición sigue teniendo sentido cuando los datos no son series de tiempo.

Para desarrollar una medida de asociación entre vectores,  $x$  e  $y$ , modificamos la definición de  $I(r)$  como sigue. Sean  $z_i = (x_i, y_i)$  con  $i = 1, \dots, N$  las observaciones en el conjunto de datos. Sea  $|z_i - z_j|$  la distancia euclidiana. Definimos  $\hat{I}(r) = \frac{1}{N^2} \sum_{i,j=1}^N I(|z_i - z_j| < r)$ . Las distancias observadas son además linealmente transformadas para que se encuentren entre 0 y 1 antes de calcular  $\hat{I}$ . Notemos que  $\hat{I}$  tiene las propiedades de una función de distribución acumulativa. Es no decreciente entre 0 y 1 y continua por la derecha. La función  $\hat{I}(r)$  describe el patrón global de distancias entre vecinos.

Nuestro interés principal es la definición de una métrica para cuantificar la asociación no lineal estudiando patrones locales. Dado esto, definimos la densidad de vecinos  $D$  de forma similar a la derivada de  $\hat{I}$ :

$$\hat{D}(r) = \frac{\Delta \hat{I}(r)}{\Delta r}$$

Donde  $\Delta \hat{I}(r)$  denota un cambio en  $\hat{I}(r)$ . La densidad de vecinos es evaluada en radio discreto  $r$ , con  $r = 0, 1/m, 2/m, \dots, 1$  y  $m$  es un grosor de malla arbitrario. Una función de suavizado automático usando validación cruzada es usada para elegir un óptimo el tamaño  $m$  (Vilela et al. 2007) y se aplica para suavizar  $D(r)$ . En el paper, el tamaño predeterminado  $m$  se establece como  $N$ , el número de observaciones y en este trabajo usaremos el mismo  $m$ . El estadístico  $\hat{D}$  es una aproximación discreta de  $d\hat{I}(r)/dr$ , la cual tiene las propiedades formales de una probabilidad función de densidad. Por lo tanto, con un ligero abuso de terminología nos referimos a  $\hat{D}(r)$  como una distribución.

En base a esto definimos la correlación local. Intuitivamente, las distancias entre los puntos de datos entre dos variables correlacionadas diferirían de las distancias entre dos variables no correlacionadas. Sea  $\widehat{D}_0(r)$  la estimación de una distribución nula, que se compone de dos vectores sin asociación. Definimos la correlación local ( $\ell(r)$ ) como la desviación de  $D$  de la de la distribución nula a una distancia vecina dada  $r$ :

$$\ell(r) = \hat{D}(r) - \widehat{D}_0(r)$$

Este enfoque no asume ninguna distribución paramétrica. La flexibilidad de este método facilita el cambio de la distribución nula a cualquier distribución de interés.

Por ultimo, definimos el coeficiente como de correlación local máxima, o coeficiente de Chen como:

$$M = \max_r \{|\ell(r)|\}$$

La interpretación de  $\ell(r)$  como la diferencia de dos distribuciones implica que  $M$  puede interpretarse como la distancia bajo la norma del supremo entre  $\hat{D}$  y  $\widehat{D}_0$ . En otras palabras, definimos el estadístico  $M$  como la desviación máxima entre dos densidades vecinas subyacentes.

## 3.5. Correlación de Pearson

### 3.5.1. Discucion sobre el coef.

donde se publico, como su ocupa, despcion en palabras

## 3.6. Definiciones

El coef. se define como:

$$\rho_{X,Y} = \frac{cov(X,Y)}{\sigma_X \sigma_Y} \quad (3.1)$$

Para una muestra de tamaño  $N$ , tenemos:

$$r = \frac{\sum_i^N (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_i^n (x_i - \bar{x})^2} \sqrt{\sum_i^n (y_i - \bar{y})^2}} \quad (3.2)$$

Con  $x_i, y_i$  elementos de la muestra y  $\bar{x}, \bar{y}$  sus respectivos promedios.

Hablar de The Ineffectiveness of the Correlation Coefficient for Image Comparisons



## Capítulo 4

# La transformación de Box y Cox

La transformación de Box y Cox, o simplemente BoxCox es una transformación no lineal propuesta por George Box y David Cox en el año 1964 en su paper *An Analysis of Transformations*. Es una transformación estadística paramétrica no lineal que es a menudo utilizada como un canal de preprocesamiento para convertir datos a una distribución normal. El método es parte de las técnicas de transformación de potencia, *power transformation*, cuyo objetivo es encontrar el parámetro  $\lambda$  que maximiza la siguiente verosimilitud.

$$\mathcal{L}(\lambda) \equiv -\frac{n}{2} \log \left[ \frac{1}{n} \sum_{j=1}^n \left( x_j^\lambda - \overline{x^\lambda} \right)^2 \right] + (\lambda - 1) \sum_{j=1}^n \log x_j \quad (4.1)$$

donde  $\overline{x^\lambda}$  es el promedio muestral del vector transformado.

Dada la selección de  $\lambda$ , la transformación está dada por:

$$y^{(\lambda)} = \begin{cases} \frac{y^\lambda - 1}{\lambda} & (\lambda \neq 0) \\ \log y & (\lambda = 0) \end{cases} \quad (4.2)$$

$\forall y \in \mathbb{R}_{>0}$ . Aunque también existe una versión para datos no positivos dada por

$$y^{(\lambda)} = \begin{cases} \frac{(y + \lambda_2)^{\lambda_1} - 1}{\lambda_1} & (\lambda_1 \neq 0), \\ \log(y + \lambda_2) & (\lambda_1 = 0). \end{cases}$$

Pero esta no es muy usada, dado que antes de aplicar la transformación suele haber un paso de preprocesamiento de los datos que la deja por sobre 0.

Nota: el siguiente parrafo mantiene las citas del paper On Box-Cox Transformation for Image Normality and Pattern Classification

El objetivo de la transformación es asegurar que se logren los supuestos para modelos lineales de modo que técnicas de análisis de varianza estándar puedan aplicarse a los datos. La transformación no cambia el ordenamiento de los datos según Bicego y Baldó [3].

Obviamente, no todos los datos se pueden transformar de esta forma para producir normalidad, sin embargo, Draper y Cox [24] argumentan que incluso en los casos en que ninguna transformación de potencia podría llevar la distribución exactamente a la normalidad, las estimaciones habituales de  $\lambda$  pueden ayudar a regularizar los datos y, finalmente, conducir a una distribución que satisfaga ciertas características como la simetría o la homocedasticidad. Esta última es especialmente útil en el reconocimiento de patrones y aprendizaje automático (p. ej., análisis discriminante lineal de Fisher)

## 4.1. BoxCox sobre imagenes

Como mencionamos en la introducción, no hay una gran cantidad de estudios que aborden la transformación BoxCox en conjunto con imágenes digitales. (ejemplos)

Notemos también que la aplicación de la transformación es un proceso iterativo en el cual se ha de buscar un parametro  $\lambda$ , esto hace que aplicar la transformación en grandes bancos de imagenes sea demoroso. Una alternativa propuesta por A. Cheddad (On Box-Cox Transformation for Image Normality and Pattern Classification) es utilizar el histograma como proxy comprimido de la matriz de datos, dado que este refleja la probabilidad estimada de que un pixel sea de un tono en particular. En lo que continua de la sección discutiremos este método.

Dada una imagen en el espacio de color RGB, definimos:

$$\mathcal{F}(u, v) = \{R(u, v), G(u, v), B(u, v)\}$$

donde  $(u, v)$  son las coordenadas en el espacio de pixeles que cumplen  $u = 1, \dots, U$ ,  $v = 1, \dots, V$  y  $(U, V)$  son las dos dimensiones de la foto. Notemos que cada elemento de la imagen es vector de tres dimensiones con los canales rojo, verde, y azul, pero en la literatura se suele trabajar con imagenes en escala de grises, para esto definimos:

$$\mathcal{F}' = (0,299R + 0,587G + 0,114 B)$$

Que correspondo al canal de escala de grises como está definido por el espacio de color  $YC_bC_r$  lo calcula. En base a esto definimos el histograma como

$$\chi(i) = \sum_{i=0}^{255} \mathcal{F}'$$
 , si tiene nivel de gris  $i$

Ahora, denotemos por  $\hat{\lambda}_\chi$  al parametro de la transformación BoxCox seleccionado usando el histograma, y de forma analoga definamos  $\lambda_{\mathcal{F}'}$  al seleccionado usando los datos completos. Fue obserado por Cheddad que estos no coinciden (de hecho la correlación entre estos es  $r^2 = -0,3022$ ) pero aun así este calculo se ha demostrado util en problemas de clasificación.



Ahora definimos  $\mathcal{F}'(u, v)^{\lambda_x}$  como los datos siendo aplicada la transformación BoxCox definida en (4.2), y por ultimo vamos a definir BoxCox para imagenes o BCI como:

$$BCI = \frac{(\mathcal{F}''(u, v) - \min(\mathcal{F}''(u, v)))}{(\max(\mathcal{F}''(u, v)) - \min(\mathcal{F}''(u, v)))}$$

con  $\mathcal{F}''(u, v) = \mathcal{F}'(u, v)^{\hat{\lambda}_x}$

Nota. mantuve la notación del paper pero creo que esta necesita una revision.  
Ahora veamos algunos ejemplos:

## Capítulo 5

# Comprando una Imagen con su transformada



## Capítulo 6

# Consideraciones Finales



## Apéndice A

# Demostraciones

En este apéndice se derivan algunos resultados preliminares asociados con la matrices de derivadas



# Bibliografía

Banerjee, A.N., and Magnus, J.R. (1999). The sensitivity of OLS when the variance matrix is (partially) unknown. *Journal of Econometrics* **92**, 295-323.